姓名：闵振昌　学号：241880334　2026 年 9 月 21 日

一. (30 points) 性能度量

某学习器 $\mathcal{L}$ 在一个三分类任务上的预测结果如表 1 所示。表中行表示真实类别，列表示预测类别。除特别说明外，结果可用分数或保留两位小数表示。

真实类别	预测类别		
	第 1 类	**第 2 类**	**第 3 类**
第 1 类	9	2	1
第 2 类	1	7	2
第 3 类	3	1	10

表 1: 学习器 $\mathcal{L}$ 的三分类混淆矩阵

1. 计算该学习器的预测准确率。（5 points）

2. 采用 one-vs-rest 方式分别构造每一类的混淆矩阵，并在四个位置标明 TP、TN、FP、FN，计算 micro-P、macro-P、micro-R 和 macro-R。（10 points）

3. 计算 micro-F1 和 macro-F1；其中 macro-F1 定义为各类别 F1 的算术平均。（5 points）

4. 在多标签分类任务中，每个样例可以同时具有多个标签。表 2 给出了 5 个样例的真实标签和学习器预测。计算 micro-P、micro-R、micro-F1、macro-P、macro-R 和 macro-F1。其中 macro 指先对每个标签分别计算指标，再对标签取算术平均。（10 points）

样例	x_1	x_2	x_3	x_4	x_5
真实标签	1,4	2	1,2,3	3,4	1,3
预测标签	1,3	2,4	1,2	2,3,4	1,3

表 2: 多标签分类结果

解: 1. 计算可得总共有 36 个样本，其中从左上开始的对角线是预测准确的

所以准确率是 $\frac{26}{36} = \frac{13}{18} \approx 0.72$

2.

真实类别	预测类别	
	是第 1 类	**非第 1 类**
是第 1 类	TP=9	FN=3
非第 1 类	FP=4	TN=20

表 3: 第 1 类的混淆矩阵

真实类别	预测类别	
	是第 2 类	**非第 2 类**
是第 2 类	TP=7	FN=3
非第 2 类	FP=3	TN=23

表 4: 第 2 类的混淆矩阵

真实类别	预测类别	
	是第 3 类	**非第 3 类**
是第 3 类	TP=10	FN=4
非第 3 类	FP=3	TN=19

表 5: 第 3 类的混淆矩阵

由这些，我们可以得到，

$$P_1 = \frac{TP_1}{TP_1 + FP_1} = \frac{9}{13} \approx 0.69 \qquad R_1 = \frac{TP_1}{TP_1 + FN_1} = \frac{9}{12} = 0.75$$
$$P_2 = \frac{TP_2}{TP_2 + FP_2} = \frac{7}{10} = 0.70 \qquad R_2 = \frac{TP_2}{TP_2 + FN_2} = \frac{7}{10} = 0.70$$
$$P_3 = \frac{TP_3}{TP_3 + FP_3} = \frac{10}{13} \approx 0.77 \qquad R_3 = \frac{TP_3}{TP_3 + FN_3} = \frac{10}{14} = \frac{5}{7} \approx 0.71$$

$$P_{\text{micro}} = \frac{\sum_{i=1}^{3} TP_i}{\sum_{i=1}^{3} TP_i + \sum_{i=1}^{3} FP_i} = \frac{26}{36} = \frac{13}{18} \approx 0.72$$
$$R_{\text{micro}} = \frac{\sum_{i=1}^{3} TP_i}{\sum_{i=1}^{3} TP_i + \sum_{i=1}^{3} FN_i} = \frac{26}{36} = \frac{13}{18} \approx 0.72$$
$$P_{\text{macro}} = \overline{P} = \frac{281}{390} \approx 0.72$$
$$R_{\text{macro}} = \overline{R} = \frac{101}{140} \approx 0.72$$

3.

$$F1_{Micro} = \frac{2P_{Micro}R_{Micro}}{P_{Micro} + R_{Micro}} = \frac{26}{36} \approx 0.72$$
$$F1_1 = \frac{2P_1R_1}{P_1 + R_1} = 0.72 \qquad F1_2 = \frac{2P_2R_2}{P_2 + R_2} = 0.7 \qquad F1_3 = \frac{2P_3R_3}{P_3 + R_3} = \frac{20}{27}$$
$$F1_{Macro} = \frac{F1_1 + F1_2 + F1_3}{3} \approx 0.72$$

4.

对于这个任务，总共有 {1,2,3,4} 四个标签

对每个标签讨论他们的混淆矩阵和 P-R

对于标签 1，真实的有 x_1, x_3, x_5，预测的也是 x_1, x_3, x_5

所以

$$TP_1 = 3 \qquad FP_1 = 0 \qquad FN_1 = 0$$
$$P_1 = 1 \qquad R_1 = 1 \qquad F1_1 = 1$$

同样的对标签 2,3,4 也进行这样的计算

$$TP_2 = 2 \qquad FP_2 = 1 \qquad FN_2 = 0$$

$$P_2 = \frac{2}{3} \qquad R_2 = 1 \qquad F1_2 = 0.8$$

$$TP_3 = 2 \qquad FP_3 = 1 \qquad FN_3 = 1$$

$$P_3 = \frac{2}{3} \qquad R_3 = \frac{2}{3} \qquad F1_3 = \frac{2}{3}$$

$$TP_4 = 1 \qquad FP_4 = 1 \qquad FN_4 = 1$$

$$P_4 = 0.5 \qquad R_4 = 0.5 \qquad F1_4 = 0.5$$

$$P_{micro} = \frac{8}{11} \qquad R_{micro} = 0.8 \qquad F1_{micro} = \frac{16}{21}$$

$$P_{macro} = \frac{17}{24} \qquad R_{macro} = \frac{19}{24} \qquad F1_{macro} = \frac{89}{120}$$

二. (30 points) 排序与曲线性能度量

某二分类数据集包含 10 个样例。标签 1 表示正例，标签 0 表示负例。学习器输出值表示样例属于正类的置信度，且已按从高到低排序，如表 6 所示。

样例	x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8	x_9	x_{10}
标签	1	0	1	1	0	0	1	0	1	0
输出值	0.94	0.87	0.81	0.72	0.66	0.58	0.47	0.35	0.22	0.11

表 6: 二分类样例及学习器输出

从阈值高于 0.94 开始逐步降低阈值。对于 $k = 1, 2, \ldots, 10$，将前 k 个样例判为正例，其余样例判为负例。按 P-R 曲线绘图惯例取初始点 $(0, 1)$。

1. 计算每一步 P-R 曲线端点的坐标 (R, P) 并绘制 P-R 曲线。绘图时可加入初始点 $(0, 1)$。（8 points）

2. 计算包括初始点在内的 ROC 曲线端点坐标 $(\mathrm{FPR}, \mathrm{TPR})$，并绘制 ROC 曲线。（8 points）

3. 使用梯形法计算 ROC 曲线下面积 AUC，结果保留两位小数。（6 points）

4. FPR80 表示真正例率为 80% 时的假正例率。说明该指标越高越好还是越低越好，并求阈值下降过程中首次达到 $\mathrm{TPR} = 80\%$ 时的 FPR80。（8 points）

解:

三. (10 points) 数据预处理

某一维特征在 5 个样例上的取值为

$$18, \quad 21, \quad 24, \quad 27, \quad 30.$$

1. 写出将特征映射到区间 $[x'_{\min}, x'_{\max}]$ 的 Min-max 归一化公式，以及 Z-score 标准化公式。（2 points）

2. 使用 Min-max 归一化将全部取值映射到区间 $[-1, 1]$。（3 points）

3. 使用 Z-score 对全部取值进行标准化。本题中的标准差采用总体标准差，即分母为样本数 m。（3 points）

4. 若在数据中加入一个新的取值 60，不必重新计算所有结果，请分别说明它会如何影响原有样例的 Min-max 归一化值和 Z-score 标准化值。（2 points）

解:

四. (30 points) 模型比较检验

在一个二分类任务中，需要比较学习器 A 与学习器 B 的泛化性能。研究者进行了 5 次 2 折交叉验证；每次实验前都重新随机打乱并划分数据，尽量避免 5 次实验采用重复的数据划分，再交换训练集与测试集完成两折测试。表 7 给出了两种学习器在每一折上的测试错误率（错误率越低越好）。

实验次数	A：第 1 折	B：第 1 折	A：第 2 折	B：第 2 折
1	0.18	0.24	0.22	0.26
2	0.20	0.25	0.19	0.22
3	0.17	0.24	0.23	0.26
4	0.21	0.25	0.20	0.22
5	0.16	0.22	0.21	0.25

表 7: 5×2 交叉验证测试错误率

定义第 i 次实验两折上的成对差值为

$$\Delta_i^{(j)} = E_{A,i}^{(j)} - E_{B,i}^{(j)}, \qquad j \in \{1, 2\},$$

并令

$$\bar{\Delta}_i = \frac{\Delta_i^{(1)} + \Delta_i^{(2)}}{2}, \qquad \sigma_i^2 = \left(\Delta_i^{(1)} - \bar{\Delta}_i\right)^2 + \left(\Delta_i^{(2)} - \bar{\Delta}_i\right)^2.$$

检验统计量定义为

$$\tau_t = \frac{\bar{\Delta}_1}{\sqrt{\frac{1}{5}\sum_{i=1}^{5} \sigma_i^2}}.$$

原假设 H_0 为“两种学习器的泛化性能相同”。按本题给出的 5×2 交叉验证检验规则，在 H_0 下将统计量 τ_t 与自由度为 5 的 t 分布进行比较。本题采用双边检验；显著性水平 $\alpha = 0.05$ 和 $\alpha = 0.01$ 对应的临界值分别为 2.5706 和 4.0321。

1. 说明为什么必须对同一次数据划分上的结果作“配对”比较，并简述 5×2 交叉验证相对普通 k 折交叉验证配对 t 检验的主要作用。（6 points）

2. 计算十个差值 $\Delta_i^{(j)}$、五个均值 $\bar{\Delta}_i$ 和五个方差 σ_i^2。（8 points）

3. 计算检验统计量 τ_t。（8 points）

4. 分别在 $\alpha = 0.05$ 和 $\alpha = 0.01$ 下判断两种学习器是否存在显著性能差异；若存在，请指出哪一种学习器更优并说明依据。（8 points）

解: