姓名：张三　学号：123456789　2026 年 10 月 23 日

一. (30 points) 线性回归与冗余属性

考虑一元线性回归模型 $\hat{y} = wx + b$，最小化 $J(w,b) = \frac{1}{2}\sum_{i=1}^{m}(y_i - wx_i - b)^2$。数据如下，记训练集均值为 $\bar{x}$ 与 $\bar{y}$。

训练样本	1	2	3	4
x	0	1	2	3
y	1	2	2	3

测试样本	1	2
x	4	5
y	4	4

1. 对 J 分别关于 b 和 w 求导，推导 $b^* = \bar{y} - w^*\bar{x}$ 与 w^* 的表达式。假设 $\sum_i (x_i - \bar{x})^2 > 0$。（10 points）

2. 求本题训练集上的 w^*, b^*，计算两个测试样本的预测值及测试集均方误差 $\text{MSE} = \frac{1}{n}\sum_i (y_i - \hat{y}_i)^2$。（5 points）

3. 为每个样本增加属性 $x_2 = 2x$，模型变为 $\hat{y} = w_1 x + w_2 x_2 + b$。说明 (w_1, w_2) 是否唯一，并写出两组能得到与第 2 问相同预测的参数。测试样本也满足 $x_2 = 2x$。（5 points）

4. 补全以下代码中的两个函数，输出参数、测试预测值和 MSE。只能使用 NumPy 实现核心计算，不使用现成回归模型。（10 points）

```python
import numpy as np
X_train = np.array([[0.], [1.], [2.], [3.]])
y_train = np.array([1., 2., 2., 3.])
X_test = np.array([[4.], [5.]])
y_test = np.array([4., 4.])
def linear_regression(X_train, y_train):
    # X_train: (m, 1); y_train: (m,)
    pass  # Return scalar w and scalar b.
def MSE(y_true, y_pred):
    pass  # Return the mean squared error.
w, b = linear_regression(X_train, y_train)
y_pred = w * X_test[:, 0] + b
print(w, b, y_pred, MSE(y_test, y_pred))
```

Listing 1: 线性回归代码样例

解:

二. (25 points) 对数几率回归与类别不平衡

某二分类任务规定少数类为正类 $y=1$，多数类为负类 $y=0$。对数几率回归输出正类概率

$$p(\mathbf{x})=\frac{1}{1+\exp[-(\mathbf{w}^{\top}\mathbf{x}+b)]}.$$

给定已训练模型在 10 个评价样本上的输出如下。此模型的训练集共有 100 个样本，其中正类 20 个、负类 80 个；下表不是训练集。

编号	1	2	3	4	5	6	7	8	9	10
y	0	0	0	0	0	0	0	0	1	1
p	.05	.10	.15	.20	.25	.30	.35	.55	.40	.80

规定：使用阈值 t 时，$p\geq t$ 判为正类，否则判为负类。所有问题均保持模型参数不变。

1. 当阈值为 0.5 时，将预测规则等价改写为关于 $\mathbf{w}^{\top}\mathbf{x}+b$ 的不等式（消去概率 p），并说明该模型决策边界的形状。（5 分）

2. 分别在阈值 0.5 与 0.3 下，计算 TP, FP, TN, FN 及准确率、查准率、查全率。说明降低阈值对本题结果的影响。（8 points）

3. 按教材第 3.6 节的再缩放思想，本题规定当

$$\frac{p}{1-p}\geq\frac{m^{+}}{m^{-}}$$

时判为正类，其中 m^{+}, m^{-} 分别为训练集正、负例数。推导等价的概率阈值，求其在本题的数值。简述这种固定模型调整阈值的方法与欠采样后重新训练的区别，不要求二者效果相同。（7 points）

4. 补全以下函数，返回第 2 问所需的计数和指标，并用两个阈值核对手算结果。（5 points）

```python
import numpy as np
y = np.array([0, 0, 0, 0, 0, 0, 0, 0, 1, 1])
p = np.array([.05, .10, .15, .20, .25,
              .30, .35, .55, .40, .80])
def evaluate(y, p, threshold):
    # Return: TP, FP, TN, FN, accuracy, precision, recall.
    # If a metric denominator is zero, return 0.
    pass
for t in [0.5, 0.3]:
    print(t, evaluate(y, p, t))
```

Listing 2: 分类评价代码框架

提示：准确率 $=\frac{TP+TN}{TP+FP+TN+FN}$，查准率 $=\frac{TP}{TP+FP}$，查全率 $=\frac{TP}{TP+FN}$。

解:

三. (20 points) 连续属性划分与缺失值

二分类数据集 D 含 8 个样本，连续属性 x 与类别 y 如下。每个样本的初始权重均为 1；$\tilde{D}$ 表示属性 x 不缺失的样本集合。对数以 2 为底，结果保留三位小数。

编号	1	2	3	4	5	6	7	8
x	1	2	3	4	5	6	缺失	缺失
y	0	0	1	1	0	1	0	1

按 $x \le t$ 和 $x > t$ 将非缺失样本划分为左、右两个分支。

1. 列出由相邻不同属性值的中点构成的全部候选阈值，计算非缺失样本集合的熵 $H(\tilde{D})$。（5 points）

2. 为减少计算，本问只比较 $t = 2.5$ 与 $t = 4.5$。分别计算它们在 $\tilde{D}$ 上的信息增益，并从这两个阈值中选出更优者。（5 points）

3. 考虑缺失值时，按教材方法使用

$$\mathrm{Gain}(D, x, t) = \rho\,\mathrm{Gain}(\tilde{D}, x, t), \qquad \rho = \frac{|\tilde{D}|}{|D|}.$$

计算第 2 问两个阈值修正后的信息增益，判断选择是否改变。（5 points）

4. 使用第 2 问选出的阈值。按非缺失样本在各分支的权重占比，将每个缺失样本以相应权重同时下传到左右分支。写出样本 7 和 8 各自在左右分支的权重，并计算分配后左右分支的正、负类权重总和。（5 points）

提示：$H(S) = -\sum_{c\in\{0,1\}} p_c \log_2 p_c$，规定 $0 \log_2 0 = 0$。第 2 问只在非缺失样本上计算

$$\mathrm{Gain}(\tilde{D}, x, t) = H(\tilde{D}) - \frac{|\tilde{D}_L|}{|\tilde{D}|} H(\tilde{D}_L) - \frac{|\tilde{D}_R|}{|\tilde{D}|} H(\tilde{D}_R).$$

解:

四. (25 points) 决策树的预剪枝与后剪枝

某数据集有两个二值属性 $A, B \in \{0, 1\}$。训练集与验证集的样本统计如下，每行表示相同属性取值下各类别的样本数量。

属性		训练集		验证集	
A	B	$y=0$	$y=1$	$y=0$	$y=1$
0	0	7	0	3	0
0	1	0	3	0	2
1	0	0	4	0	2
1	1	2	0	3	0

本题**固定划分顺序**：先在根节点按 A 划分，再在两个子节点分别按 B 划分，不要求比较划分指标。叶节点的预测类别始终由到达该节点的**训练样本多数类**决定；若数量相同则预测 0。

1. 写出根节点不划分时的预测类别、按 A 划分后两个叶节点的预测类别，以及完整两层树四个叶节点的预测类别。（5 points）

2. 预剪枝规则为：只有划分后**整棵树的验证准确率严格提高**，才允许该划分。计算根节点划分前、后的验证准确率，确定预剪枝结果。（7 points）

3. 从完整两层树开始进行后剪枝，顺序为：先检查 $A = 0$ 子树，再检查 $A = 1$ 子树，最后检查根节点。每次把待检查子树替换为一个多数类叶节点；若整棵树的验证准确率不下降，就保留该剪枝，否则恢复子树。计算各次候选剪枝后的验证准确率，画出或用清晰规则表示最终树。（8 points）

4. 结合本题解释为什么预剪枝和后剪枝可能得到不同结果，并说明验证集与测试集在剪枝实验中的不同用途。（5 points）

提示：训练集共 16 个样本，验证集共 10 个样本。后剪枝被拒绝后，下一步仍以恢复后的树为基础。本题只需手算与分析，不要求另选数据集或实现剪枝算法。

解: